

## Optimización analítica: otro ejemplo

- Estimar los parámetros de una gaussiana multivariada (en  $\mathbb{R}^D$ ), con  $\Sigma$  dada:

$$p(\mathbf{x}; \Theta) = (2\pi)^{-D/2} |\Sigma|^{-1/2} \exp \left( -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right)$$

donde  $\Theta \equiv (\boldsymbol{\mu}, \Sigma)$ . Si  $\Sigma$  está prefijada, entonces  $\Theta \equiv \boldsymbol{\mu} \in \mathbb{R}^D$

- Logaritmo de la verosimilitud de una muestra  $S = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ :

$$\begin{aligned} q_S(\Theta) \equiv L_S(\Theta) &= \log \prod_{n=1}^N p(\mathbf{x}_n; \Theta) = \sum_{n=1}^N \log p(\mathbf{x}_n; \Theta) \\ &= N \log \left( (2\pi)^{-D/2} |\Sigma|^{-1/2} \right) - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})^t \Sigma^{-1} (\mathbf{x}_n - \boldsymbol{\mu}) \end{aligned}$$

- Para una estimación de máxima verosimilitud basta hacer  $\nabla L_S(\Theta) = \mathbf{0}$ .  
Si  $\Sigma$  está prefijada, se obtiene (*ejercicio*):

$$\hat{\boldsymbol{\mu}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

3.3. (p.3.10, 0.25 puntos) Desarrollar con detalle todos los pasos necesarios para obtener el estimador de máxima verosimilitud del vector media de una de una gaussiana multivariada cuya matriz de covarianza es fija y conocida, a partir de una muestra de de vectores  $x_1, x_2, \dots, x_N$ .

$$p(x; \theta) = (2\pi)^{-\frac{D}{2}} |\Sigma|^{-\frac{1}{2}} \cdot e^{\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^t \Sigma^{-1}(\vec{x} - \vec{\mu})\right)}$$

Logaritmo de la verosimilitud

$$L_s(\theta) = \log \left( \prod_{n=1}^N \underbrace{\left(2\pi^{-\frac{D}{2}}\right)}_A \underbrace{|\Sigma|^{-\frac{1}{2}}}_{B} \cdot e^{\left(-\frac{1}{2}(\vec{x}_n - \vec{\mu})^t \Sigma^{-1}(\vec{x}_n - \vec{\mu})\right)} \right) = \log \left( \prod_{n=1}^N (A \cdot B \cdot e^C) \right)$$

$$= \log \left( A^N \cdot B^N \cdot e^{\left(\sum_{n=1}^N \left(-\frac{1}{2}(\vec{x}_n - \vec{\mu})^t \Sigma^{-1}(\vec{x}_n - \vec{\mu})\right)\right)} \right)$$

$$= \log A^N + \log B^N + \sum_{n=1}^N \left(-\frac{1}{2}(\vec{x}_n - \vec{\mu})^t \Sigma^{-1}(\vec{x}_n - \vec{\mu})\right)$$

$$= \frac{-ND}{2} \log(2\pi) - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{n=1}^N \left((\vec{x}_n - \vec{\mu})^t \Sigma^{-1}(\vec{x}_n - \vec{\mu})\right)$$

$$L_s(\theta) = -\frac{ND}{2} \log(2\pi) - \frac{N}{2} \log |\Sigma| - \frac{1}{2} \sum_{n=1}^N ((\vec{x}_n - \vec{\mu})^T \Sigma^{-1} (\vec{x}_n - \vec{\mu}))$$

Derivamos en función de  $\vec{\mu}$

$$\frac{\partial}{\partial \vec{\mu}} = 0 - 0 - \frac{1}{2} \sum_{n=1}^N (2 \cdot \Sigma^{-1} (\vec{x}_n - \vec{\mu}))$$

$$\frac{\partial}{\partial \vec{\mu}} = - \sum_{n=1}^N (\Sigma^{-1} \cdot (\vec{x}_n - \vec{\mu}))$$

Igualemos a 0

$$\sum_{n=1}^N (\Sigma^{-1} \cdot (\vec{x}_n - \vec{\mu})) = 0 \Rightarrow \Sigma^{-1} \sum_{n=1}^N (\vec{x}_n - \vec{\mu}) = 0$$

Dado que  $\Sigma$  está predefinida, la expresión solo se cumple si:  $\sum_{n=1}^N (\vec{x}_n - \vec{\mu}) = 0$

$$\Rightarrow \sum_{n=1}^N (\vec{x}_n - \vec{\mu}) = 0 \Rightarrow \sum_{n=1}^N \vec{x}_n - \sum_{n=1}^N \vec{\mu} = 0 \Rightarrow \sum_{n=1}^N \vec{x}_n - N\vec{\mu}$$

$$\Rightarrow \vec{\mu} = \frac{\sum_{n=1}^N \vec{x}_n}{N}$$

Dado que  $\Sigma$  es simétrica,  $\Sigma^{-1}$  también lo es y como  $(\vec{x}_n - \vec{\mu})$  no depende de  $\Sigma^{-1}$ , podemos aplicar la fórmula para el gradiente de una forma cuadrática

$$\frac{\partial \vec{z}^T A \vec{z}}{\partial \vec{z}} = 2 A \vec{z}$$